

Open Patient- Ψ : 오픈소스 LLM 기반 환자 시뮬레이션 시스템*

정윤서⁰¹ 한승헌¹ 성무진^{1**}

¹경희대학교 컴퓨터공학부

jys0615234@gmail.com hsh019@khu.ac.kr mujeensung@khu.ac.kr

Open Patient- Ψ : An Open Source LLM-Based Patient Simulation System

Yoonsuh Jung⁰¹ Seungheon Han¹ Mujeen Sung¹

¹School of Computing, Khung Hee University

jys0615234@gmail.com hsh019@khu.ac.kr mujeensung@khu.ac.kr

요약

연구는 정신건강 상담 교육을 위한 환자 시뮬레이션 시스템에서 GPT-4 기반 모델의 비용 및 폐쇄성 한계를 해결하고자 오픈소스 언어모델 기반의 Open Patient- Ψ 시스템을 제안한다. 먼저 Patient- Ψ [1] 논문 구조를 충실히 반영하여 총 1300개의 환자 시뮬레이션 데이터를 구축하고, QLoRA 기법[3]을 활용하여 Qwen2.5 모델(0.5B/3B)[4]을 파인튜닝하였다. 훈련은 1000개 샘플로 수행되었으며, 100개의 검증 데이터셋을 활용하여 총 25개 하이퍼파라미터 조합 중 최적 조합을 자동으로 선정하였다. 이후 테스트셋 200개를 기반으로 최적 모델과 GPT-4.1-nano 간의 응답을 비교 평가하였다. 평가 방법으로는 BERTScore[2], 핵심 정보 포함도 정량 평가, LLM 기반 정성 평가를 도입하였다. 그 결과, Open Patient- Ψ 모델은 GPT-4.1-nano에 근접한 응답 품질을 보였고, 오픈 소스 모델 기반 시뮬레이션의 가능성을 입증하였다. 본 연구는 향후 AI 피드백 기반 강화학습(RLAIF), 멀티 참조 평가 구조를 향후 확장 가능성으로 제시한다.

1. 서론

정신건강 상담 교육에서 환자 시뮬레이션 기능은 중요한 역할을 담당한다. 치료사가 시뮬레이션을 통해서 실제 환자를 대할 때를 대비해 효과적인 전략 및 준비를 할 수 있기 때문이다. 최근 Patient- Ψ [1] 연구는 실제 상담 훈련에서 사용이 가능한 고품질의 환자 응답을 자동 생성하는 LLM 기반의 시스템을 제안하였다. 그러나 해당 시스템은 GPT-4 기반으로 이러한 접근 및 설계는 높은 비용, 폐쇄성, 프라이버시 문제 등의 한계를 드러낸다. 본 연구에서는 오픈소스 LLM 기반으로 Patient- Ψ 구조를 재현 및 확장한 Open Patient- Ψ 모델을 제안한다. 순서는 다음과 같다. 기존 연구에서 설계된 시뮬레이션 데이터를 생성하고, 이를 통해 Qwen 시리즈[4]의 LLM을 QLoRA 방식[3]으로 파인튜닝한다. 다음으로는 GPT 기반의 자동 평가 체계를 통해 정량적 비교 실험을 수행한다.

우측의 그림 1에서 연구의 세부적인 절차를 확인할 수 있다. 정신건강 상담 교육에 활용 가능한 환자 시뮬레이션 데이터셋을 구축하기 위해 기존 PATIENT- Ψ 논문[1]에서 제안한 구조를 구현하고 자체적인 모델 학습을 진행했다.




그림 1. Open Patient- Ψ 연구의 전체적인 방향

2. 시뮬레이션 데이터셋 구축

데이터는 총 1300개의 샘플로 구성되며, 각 샘플은 인지모델(Core Belief, Dysfunctional Thought 등), 환자의 발화 스타일, 상담 맥락(Context), 그리고 시뮬레이션 환자로 인식한 GPT 기반 응답으로 이루어진다.

* 본 연구는 과학기술정보통신부 및 정보통신기획평가원의 2025년도 SW 중심 대학 사업의 결과로 수행되었음 (2023-0-00042)

** 교신저자 (Corresponding Author)

데이터 생성은 두 단계로 진행되었다. 우선, GPT-4-Turbo 기반 모델을 활용해 대량의 초기 응답 후보를 생성하고, 이를 다시 모델이 올바르게 학습할 수 있도록 ChatML 형식으로 변환하였다. 이 과정에서 기존 연구 논문에서 명시된 모델 학습용 프롬프트를 변환 과정에 추가하여 논문의 구현도를 따랐다. 생성된 1300개 데이터 중 1000개는 훈련용으로, 100개는 하이퍼파라미터 검증용, 나머지 200개는 최종 성능 평가용으로 구분하여 활용하였다.

3. 모델 학습

모델 학습은 다음과 같다. QLoRA[3] 기반의 파인튜닝 기법을 활용하여 오픈소스 언어 모델인 Qwen2.5-0.5B-Instruct[4]와 Qwen2.5-3B-Instruct[4]에 대해 시뮬레이션 환자 데이터셋을 학습했다. 훈련 데이터를 기반으로 모델을 학습하였고, 학습 과정에서 GPU 자원을 효율적으로 활용하고자 LoRA 어댑터 방식과 4비트 양자화를 적용했다.

3.1 하이퍼파라미터 탐색

모델 성능을 극대화하기 위해 총 25개의 하이퍼파라미터 조합(5가지 학습률 $\times$ 5가지 에폭 수)을 실험하였다. 각 조합은 동일한 초기 조건에서 학습되었으며, 학습 종료 후 검증 데이터셋 100개를 기반으로 응답을 생성하여 평가를 수행하였다. 평가는 BERTScore[2] 기반 지표를 사용하였고, GPT-4.1 기반 응답을 기준(reference)으로 하여 후보 응답의 언어적 유사성과 표현 품질을 정량적으로 비교하였다. BERTScore[2]는 roberta-large 모델을 백본으로 활용하였으며, 정규화(normalization) 및 최대 5문장 truncation 등의 전처리 적용으로 평가의 일관성과 신뢰성을 높였다. Open Patient- Ψ (0.5B) 모델은 에폭 수 2, 학습률 $4e-4$ 가 선택되었고, Open Patient- Ψ (3B) 모델은 에폭 수 6, 학습률 $5e-4$ 가 선택되었다.

4. 테스트셋 기반 최종 평가

최종 평가는 테스트셋을 기반으로 Open Patient- Ψ 모델과 비교 모델인 GPT-4.1-nano 모델의 응답을 생성하였다. 세 가지 기준에 따라 모델 성능에 대한 정량적 분석을 수행했다. 사용된 평가 기준은 정확도(Accuracy), 충실도(Fidelity), 포인트와이즈 비교(Pointwise Evaluation)이다. 정확도와 충실도는 기존 Patient- Ψ 연구[1]에서 진행되었던 방식을 구현하였다. 모든 평가 과정은 LLM 기반의 자동 평가 방식으로 진행되었다. 전문가의 개입 없이 객관적이고 일관된 평가 결과를 도출하고자 하였다.

4.1 포인트와이즈 비교 평가 (Pointwise Evaluation)

Pointwise 평가는 동일한 테스트 입력에 대해 두 개의 모델 응답(예: Open Patient- Ψ (0.5B)와 GPT-4.1-nano)을 비교하여 상대적인 품질을 판별하는 방식으로 진행되었다. 평가 모델 GPT-4.1-mini는 응답 A와 B를 함께 제공받고, 다음 세 가지 기준에 따라 더 우수한 응답을 선택하였다. 정서적 현실감, 환자의 배경과 심리 프로파일과의 정합성,

그리고 인지행동치료(CBT) 맥락에서의 적절성이다. 그림 2과 3은 Open Patient- Ψ (0.5B)와 GPT-4.1-nano, Open Patient- Ψ (3B)와 GPT-4.1-nano의 평가 결과다. 두 모델 모두 GPT-4.1-nano보다 더 선택을 받은 것을 확인된다.




그림 2. Open Patient- Ψ (0.5B) 포인트와이즈 평가 결과




그림 3. Open Patient- Ψ (3B) 포인트와이즈 평가 결과

4.2 정확도 평가 (Accuracy)

정확도 평가는 GPT-4.1-mini가 환자 응답을 읽고 주어진 선택지들 중 하나를 골라서 실제 정답과 일치했는지를 측정하는 값이다. 총 5개의 항목에 대해 텍스트 기반 정확도를 평가하고, 핵심 신념, 감정, 세분화된 핵심 신념에 대해서는 F1 점수 기반으로 평가가 이루어졌다. 아래 [표 1]과 [표 2]에서 각 모델의 평가값을 확인할 수 있다. 모델의 답변이 임상 개념을 얼마나 반영했는가를 측정 지표로서 활용이 가능한 부분이다. 세분화된 핵심 신념은 Patient- Ψ 논문[1]처럼 기존 핵심 신념보다 낮은 수치를 보이는 걸 알 수 있다.

[표 1] Open Patient- Ψ (0.5B) 정확도 평가 결과

텍스트 기반	정확도	분류	F1 점수
상황	0.18	핵심 신념	0.398
대처 전략	0.225	감정	0.342
중간 신념	0.26	핵심 신념(세분화)	0.377
자동적 사고	0.22		
행동	0.24		

[표 2] Open Patient- Ψ (3B) 정확도 평가 결과

텍스트 기반	정확도	분류	F1 점수
상황	0.22	핵심 신념	0.391
대처 전략	0.245	감정	0.342
중간 신념	0.225	핵심 신념(세분화)	0.375
자동적 사고	0.215		
행동	0.22		

4.3 표현 충실도 평가 (Fidelity)

충실도 평가는 모델 응답이 주어진 대화 맥락과 얼마나 자연스럽게 일관되게 연결되는지를 측정하기 위해 수행되었다. 이를 위해 각 테스트 입력은 conversation, model_response, dimension의 세 요소로 구성되며, 평가 기준은 감정 상태, 표현 스타일, 인지 일치성 등 다양한 심리적 차원을 포함한다. 각 입력에 대해 generate_fidelity_prompt() 함수를 통해 평가용 프롬프트를 생성하고, 평가자는 GPT-4.1-mini로 설정하여 수행하였다. GPT-4.1-mini는 각 응답에 대해 1점에서 6점의 정수 점수를 반환하며, 이를 수집하여 평균 점수와 표준편차를 산출했다.




그림 4. Open Patient- Ψ (0.5B) 표현 충실도 평가 결과

이는 그림 4, 5에 나와있으며 근소하게 GPT-4.1-nano 모델이 근소하게 우위를 점하는 것을 확인할 수 있다. 비교 모델과 평가 모델이 버전은 다르지만, 같은 GPT 모델인 것으로 인한 모델 편향이 발생한 것으로 해석된다.

본 연구의 기반이 된 Patient- Ψ 연구 논문[1]에서도 전문가 평가는 논문에서 학습한 모델이 우수 평가를 받았으나, GPT, LLaMA 모델들은 GPT가 더 우수하다고 평가한

것이다. 후속 연구에서는 편향 보정과 관련 진전이 있어야 할 것이다.




그림 5. Open Patient- Ψ (3B) 표현 충실도 평가 결과

5. 향후 연구 및 결론

본 연구에서는 정신건강 상담 교육을 위한 환자 시뮬레이션 시스템을 오픈소스 언어모델 기반으로 구현한 Open Patient- Ψ 를 제안했다. 기존 GPT-4 기반 시뮬레이션의 비용적 보안적 제약을 극복을 하고자 QLoRA 기법[3]을 활용해 Qwen2.5-0.5B 및 3B 모델[4]을 파인튜닝하였고, 이를 통해 환자 시뮬레이션 모델을 자체적으로 구축하였다. 또한, 총 1300개의 시뮬레이션 데이터를 PATIENT- Ψ 구조에 기반해 설계하여 이를 학습, 검증, 테스트 데이터 세트로 분할 및 체계적인 학습과 평가를 수행하였다.

본 연구는 다음으로 확장을 제안한다. Self-Rater 기반의 AI Feedback을 기본 구조로 보상 신호를 학습에 반영하는 RLAIIF를 적용함으로써 모델의 정합성과 인간 유사성을 더욱 향상시키는 것이 가능하다. 오픈모델 기반 시뮬레이션의 가능성과 효용성을 실증한 연구로서 의료 AI 교육 및 평가 환경의 자동화 및 표준화에 기여할 수 있을 것이라고 기대한다.

6. 참고 문헌

- [1] Wang, R., et al., "PATIENT- Ψ : Using Large Language Models to Simulate Patients for Training Mental Health Professionals", Proceedings of the EMNLP, 2024
- [2] Zhang, T., et al., "BERTScore: Evaluating Text Generation with BERT", Proceedings of the ICLR, 2020
- [3] Dettmers, T., et al., "QLoRA: Efficient Finetuning of Quantized LLMs", Proceedings of the NeurIPS, 2023
- [4] Yang A., et al. "Qwen2.5 Technical Report", arXiv preprint arXiv:2412.15115, 2024